Universidad de Carabobo
Facultad de Ingeniería
Dirección de Postgrado
Programa de Maestría en Matemática y Computación
Cálculo Avanzado

Asignación 2

Realice en manuscrito los siguientes problemas:

1. Se dice que una función $f : R^n \to R$ es homogénea de grado k si existe $k \in R$ tal que:

$$f(tX) = t^k f(X)$$

Demuestre que si f es homogénea de grado k, entonces se cumple que:

$$X \bullet \nabla f(X) = k f(X)$$

2. El método de los mínimos cuadrados consiste en lo siguiente: suponga que experimentalmente se obtienen n pares que representan las mediciones de dos variables x e y :

$$(x_1, y_1) \; ; \; (x_2, y_2) \; ; \; (x_3, y_3) \; ; \; ...(x_n, y_n) \; .$$

Es razonable suponer que estas variables estan relacionadas linealmente; es decir, $y = mx + b$. No obstante, las medidas de las variables tienen un error experimental. Para hallar los valores de m y b, es deseable que la diferencia entre los valores y_i reales y los calculados con la función lineal dada, sea lo menor posible. Es posible lograr esto si la suma de los cuadrados de los errores cometidos en cada medición es mínima:

$$S = S(m, b) = (y_1 - mx_1 - b)^2 + (y_2 - mx_2 - b)^2 + (y_3 - mx_3 - b)^2 + ... + (y_n - mx_n - b)^2$$

Demuestre que la función $S(m, b)$ tiene un sólo punto crítico, y que en éste punto crítico esta función tiene un mínimo.

1/13 Asignación Dos. Calculo Avanzado

1.) Se dice que una función $F: R^n \to R$ es homogenea de grado k si existe $k \in R$ tal que:

$$f(tX) = t^k f(X)$$

Demuestre que si f es homogenea de grado k entonces se cumple que:

$$X \cdot \nabla f(X) = k f(X)$$

solución:

Siendo X un vector $\in R^n$ se puede escribir en sus componentes como

$$X = (x_1, x_2, x_3, \ldots x_n)$$

si hacemos el producto de un escalar t por X tenemos

$$tX = (tx_1, tx_2, tx_3 \ldots, tx_n)$$

por lo que partiendo de la definición inicial podemos reescribirla como

$$f(tx_1, tx_2, tx_3, \ldots tx_n) = t^k f(x_1, x_2, \ldots x_n)$$

Derivamos a ambos lados de la ecuación con respecto a t, dado que la igualdad se cumple para todo t escribimos:

$$\frac{d}{dt}[f(tx_1, tx_2, \ldots, tx_n)] = \frac{d}{dt}[t^k f(x_1, x_2 \ldots x_n)]$$

para el lado derecho $f(x_1, x_2, \ldots x_n)$ actua como una constante por lo que derivamos solo t^k, asi

$$\frac{d}{dt}[t^k f(x_1, x_2 \ldots x_n)] = k t^{k-1} \cdot f(x)$$

para el lado izquierdo, se aplica la regla de la cadena multivariable haciendo un cambio de variable de la forma

$$v_i = tx_i \text{ ; para } i = 1, 2, 3 \ldots n$$

tenemos a f escrita como

$$f(v_1, v_2, \ldots v_n)$$

3/13

siendo f una función compuesta dependiente de t y x la regla de la cadena establece así

$$\frac{d}{dt} f(v_1, v_2 \ldots v_n) = \frac{\partial f}{\partial v_1} \cdot \frac{dv_1}{dt} + \frac{\partial f}{\partial v_2} \cdot \frac{dv_2}{dt} + \ldots + \frac{\partial f}{\partial v_n} \cdot \frac{dv_n}{dt}$$

como $v_i = tx_i$ la derivada de cada componente v_i respecto de t es simplemente x_i tenemos:

$$\frac{dv_i}{dt} = x_i$$

sustituyendo en la regla de la cadena tenemos:

$$\frac{d}{dt} f(tx) = \sum_{i=1}^{n} \frac{\partial f}{\partial v_i}(tx) \cdot x_i$$

si igualamos ambas derivadas tenemos:

$$\sum_{i=1}^{n} \frac{\partial f}{\partial v_i}(tx) \cdot x_i = kt^{k-1} f(x)$$

sabemos que la ecuación es valida para cualquier valor de t por lo que evaluando la igualdad para

$t=1$ tenemos que:

a) el vector $t.X$ se convierte en X

b) las derivadas parciales $\frac{\partial f}{\partial x_i}(tX)$ se convierten en derivadas parciales estandart evaluadas en el punto original.

$$\frac{\partial f}{\partial x_i}(X)$$

c) el termino t^{k-1} es simplemente 1.

tenemos.

$$\sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(X) \cdot x_i = k(1)^{k-1} f(X)$$

$$\sum_{i=1}^{n} x_i \cdot \frac{\partial f}{\partial x_i}(X) = k \cdot f(X) \quad (A)$$

Recordando que la definicion del vector gradiente $\nabla f(X)$ es el vector formado por todas las derivadas parciales de f, tenemos.

E/13

$$\nabla f(x) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

haciendo el producto escalar entre el vector gradiente y el vector original $X = (x_1, x_2 \dots x_n)$, al multiplicar componente a componente y sumar, tenemos:

$$X \cdot \nabla f(x) = x_1 \cdot \frac{\partial f}{\partial x_1} + x_2 \frac{\partial f}{\partial x_2} + \dots + x_n \frac{\partial f}{\partial x_n}$$

$$= \sum_{i=1}^{n} x_i \frac{\partial f}{\partial x_i}(x)$$

siendo esta expresión idéntica al lado izquierdo de la expresión (A) obtenemos:

$$X \cdot \nabla f(x) = k \cdot f(x)$$

con lo que se demuestra que si una función es homogénea de grado k, el producto punto entre el vector X y su gradiente es igual a la función

multiplicada por su grado de homogeneidad k.

2°) El método de los mínimos cuadrados consiste en lo siguiente:
Supongo que experimentalmente se obtienen n pares que representan las mediciones de dos variables x e y:

(x_1, y_1); (x_2, y_2); (x_3, y_3); ...; (x_n, y_n)

Es razonable suponer que estas variables están relacionadas linealmente; es decir $y = mx + b$. No obstante, las medidas de las variables tienen un error experimental. Para hallar los valores de m y b, es deseable que la diferencia entre los valores yi reales y los calculados con la función lineal dada, sea lo menor posible. Es posible lograr esto si la suma de los cuadrados de los errores cometidos en cada medición es mínima:

7/13

$$S = S(m,b) = (Y_1 - mX_1 - b)^2 + (Y_2 - mX_2 - b)^2 + (Y_3 - mX_3 - b)^2 + \dots + (Y_4 - mX_4 - b)^2$$

Demuestre que la función $S(m,b)$ tiene un solo punto crítico, y que este punto crítico es un mínimo.

Solución:

partiendo de la expresión lineal que estamos suponiendo para este caso:

$$Y = mX + b$$

vectorizamos esto en forma vectorial. Así definimos los objetos del espacio vectorial para $\mathbb{R}^4$ de la siguiente forma

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^4 \; ; \; X = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_4 & 1 \end{pmatrix} \in \mathbb{R}^{4\times 2}$$

$$\beta = \begin{pmatrix} m \\ b \end{pmatrix} \in \mathbb{R}^2$$

8/13

Si consideramos que el producto matricial $X\beta$ genera un vector columna en $\mathbb{R}^4$ cuyas componentes son exactamente las predicciones del modelo lineal: $mx_i + b$ entonces el error de cada predicción es la diferencia entre el valor real y la predicción de la siguiente forma:

$$Y - X\beta$$

El método de los mínimos cuadrados busca minimizar la suma de los cuadrados de estos residuos, lo que es equivalente a minimizar la norma euclidiana o la longitud del vector residual usi la función objetivo escalar $S(\beta)$ que va de $\mathbb{R}^2$ a $\mathbb{R}$ se reescribe como

$$S(\beta) = \|Y - X\beta\|^2$$

por propiedades del producto interno (sabiendo que $\|V\|^2 = V^T \cdot V$)

9/13

se expande la función

$$S(\beta) = (Y - X\beta)^T (Y - X\beta)$$

aplicando propiedad distributiva a la transpuesta $(A-B)^T = A^T - B^T$ y tenemos:

$$S(\beta) = (Y^T - \beta^T X^T)(Y - X\beta)$$

$$S(\beta) = Y^T Y - Y^T X\beta - \beta^T X^T Y + \beta^T X^T X\beta$$

se observa que $\beta^T X^T Y$ es el producto de matrices de dimensiones $(1\times2)\cdot(2\times4)\cdot(4\times1)$ lo que da como resultado un escalar (1×1), dado que la transpuesta de un escalar es el mismo escalar entonces tenemos que

$$(Y^T X\beta)^T = \beta^T X^T Y$$ por lo que los terminos centrales de la expresion antes son iguales con lo que reescribimos la expresion como

$$S(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X\beta$$

Para encontrar el punto crítico aplicamos el operador vectorial gradiente ∇_β a la función $S(\beta)$ y lo igualamos a cero. Considerando las siguientes condiciones:

- la derivada de una constante $(y^T y)$ es el vector nulo 0
- la derivada de un término lineal transpuesto $(-2\beta^T c)$ es $-2c$
- la derivada de una forma cuadrática $(\beta^T A \beta$, siendo $A = X^T X$ simétrica) es $2A\beta$

con lo que obtenemos:

$$\nabla_\beta S(\beta) = -2X^T y + 2X^T X\beta = 0$$

con lo que reescribimos:

$$X^T X\beta = X^T y$$

11/13

Ahora para despejar β, la matriz X^TX debe ser invertible. Esto ocurre si y solo si la matriz X tiene rango columna completo, esto ocurre si las columnas son linealmente independientes de modo que los x_i tengan variación es decir no sean todos el mismo numero, ya que en datos experimentales esto se cumple al existir la inversa el punto β esta garantizado y es unico porque:

$$\beta_0 = (X^TX)^{-1}X^TY$$

Ahora para garantizar que el punto β_0 es un mínimo global vamos el criterio multidimensional de la segunda derivada derivando nuevamente el gradiente de S respecto a β que implica evaluar la Matriz Hessiana

$$H = \nabla^2_\beta S(\beta) = \frac{\partial}{\partial \beta}(2X^TX\beta - 2X^TY)$$

$$H = 2X^TX$$

para q la función posea un mínimo la matriz Hessiana debe ser definida positiva, de modo que H lo es si para cualquier vector arbitrario no nulo $v \in \mathbb{R}^2$, se cumple que $v^T H v > 0$

Evaluando esta condición tenemos:

$$v^T H v = v^T (2X^T X) v = 2(v^T X^T)(Xv)$$

aplicando la propiedad $(AB)^T = B^T A^T$ recordemos

$(v^T X^T) = (Xv)^T$, sustituyendo tenemos

$$v^T H v = 2(Xv)^T (Xv) = 2\|Xv\|^2$$

como la norma es siempre positiva y sabemos que X tiene rango completo por lo que Xv nunca será el vector nulo si $v \neq 0$, entonces se concluye que

$$2\|Xv\|^2 > 0$$

13/13

dado que la Hessiana es definida positiva de forma constante e independiente de β, el espacio paramétrico es convexo, por lo que cualquier punto crítico encontrado en un espacio estrictamente convexo es indiscutiblemente un mínimo global.